

Modelli di previsione per la prevenzione e Gestione del Diabete

Orazio Ferla

Appello del 7 Aprile 2025

Introduzione

Negli ultimi anni la prevenzione e la gestione del diabete rappresentano temi di primaria importanza per la salute pubblica. L'obiettivo di questa analisi è identificare i fattori chiave che influenzano l'insorgenza del diabete, sfruttando dati clinici e biochimici, al fine di supportare strategie di intervento mirate.

Obiettivo

L'obiettivo principale di questo studio è sviluppare un modello predittivo per la previsione e gestione del diabete, con due metodi distinti: Random Forest e Boosting, un'attenzione particolare sarà rivolta all'ottimizzazione dei relativi iperparametri al fine di garantire prestazioni ottimali e infine confrontando i due modelli si sceglierà quello che risulterà essere migliore per lo studio che si sta effettuando.

I Dati

Il dataset analizzato, utilizzando dei metodi di imputazione per sistemare degli eventuali errori di compilazione o di misura o di altro genere per alcune variabili (valori negativi in LDL e HDL e valori troppo elevati per BMI), e dopo aver effettuato un'analisi su dati mancanti e dati duplicati dalle quali è emersa l'assenza sia di dati duplicati che di dati mancanti, comprende 7897 osservazioni. Una sintesi delle variabili osservate è riportata nella Tabella 1.

Gli indici BMI, LDL e HDL riportati nelle osservazioni originali presentavano incongruenze relative al valore massimo per BMI e valore minimo per LDL e HDL in quanto era negativo, di conseguenza sono state corrette attraverso un'imputazione dei dati utilizzando il pacchetto R mice e specificando come metodo "pmm" (Predictive Mean Matching) che per ogni valore mancante, si costruisce un modello di regressione basato sulle variabili disponibili, successivamente si predice il valore mancante utilizzando questo modello. Dopodiché si cercano i valori osservati più vicini alla previsione e si sceglie casualmente uno di questi. Specificando $m = 5$ e $maxit = 5$. Il parametro m rappresenta il numero di dataset imputati generati, ciascuno dei quali costituisce una possibile soluzione per la gestione dei valori mancanti. Il parametro $maxit$, invece, indica il numero massimo di iterazioni effettuate in ciascun ciclo di imputazione.

Variabile	Descrizione
Age	l'età dell'individuo
BMI	indice di massa corporea, misura la percentuale di grasso corporeo in relazione ad altezza e peso
Glucose	concentrazione di glucosio nel sangue
BloodPressure	pressione arteriosa sistolica
HbA1c	livello di emoglobina glicata, rappresenta la media della glicemia negli ultimi mesi.
LDL	livello di colesterolo "cattivo"
HDL	livello di colesterolo "buono"
Triglycerides	livello di trigliceridi nel sangue
WaistCircumference	circonferenza vita (cm)
HipCircumference	circonferenza fianchi (cm)
WHR	rapporto vita/fianchi, ottenuto dividendo la circonferenza vita per quella dei fianchi.
FamilyHistory	presenza di una storia familiare di diabete, 2 livelli (1 = Sì, 0 = No)
DietType	abitudini alimentari, 4 livelli (0 = Squilibrata, 1 = Bilanciata, 2 = Vegana/Vegetariana. 3 = Sconosciuta)
Hypertension	presenza di ipertensione, 2 livelli (1 = Sì, 0 = No).
MedicationUse	utilizzo di farmaci specifici (1 = Sì, 0 = No).
Outcome	esito diagnostico per il diabete, 2 livelli (1 = Diabete, 0 = Non Diabete)

Tabella 1: Variabili presenti nel dataset

È stato ritenuto utile raggruppare in classi le variabili contenenti un elevato numero di modalità, così da rendere più chiara la distinzione del comportamento di queste variabili rispetto alla variabile di risposta Outcome. In particolare, sono state raggruppate: Age, BMI, Glucose, BloodPressure, HbA1c, LDL, HDL, Triglycerides, molte delle quali nelle analisi cliniche hanno dei valori soglia definiti dalla SIBioC (Società Italiana di Biochimica Clinica e Biologia Molecolare Clinica).

- Age : 18-35, 35-53, 53-71, 71-89.
- BMI : <18.5, 18.5-24.9, 25-29.9, ≥30.
- Glucose : <100, 100-125, ≥126.
- BloodPressure : <120, 120-129, 130-139.
- HbA1c : <5.7, 5.7-6.4, ≥6.5.
- LDL : <100, 100-129, 130-159, 160-189, ≥190.
- HDL : <40, 40-59, ≥60.
- Triglycerides : <150, 150-199, 200-499.

Inoltre per semplicità di interpretazione, le modalità di Outcome “0”, “1”, le indicheremo come 0= “No diabete” e 1= “Sì diabete”.

Analisi Esplorativa

La variabile dicotomica Outcome, rappresentante l’aver il diabete o no, contiene un numero di osservazioni molto sbilanciato tra gli “0” e gli “1” (6256 vs 1641), dove 0 indica gli individui che non


hanno il diabete, mentre 1 gli individui che hanno il diabete; questo verrà tenuto in considerazione nell'interpretazione dei risultati derivanti dall'analisi esplorativa che segue.

No diabete	Si diabete
0.7921996	0.2078004

Variabile Hypertension: L'analisi di questa variabile non restituisce risultati interessanti, probabilmente dovuti al fatto che le osservazioni per le due diverse modalità sono parecchio sbilanciate, motivo per il quale si è deciso di non riportare valori e grafico, presenti invece nel codice.

Variabile FamilyHistory : Si evince, che circa il 3% di coloro che hanno il diabete, non hanno una storia familiare di diabete. Al contrario di quello che succede tra coloro che invece hanno il diabete ma avendo una storia familiare di diabete, comunicando una maggiore tendenza ad avere il diabete se si ha una predisposizione genetica di diabete. Questo sembrerebbe coerente, poiché una predisposizione genetica di diabete comporta spesso l'insorgenza di diabete nei componenti della famiglia.

Distribuzione di FamilyHistory rispetto ad Outcome




	No Diabete	Si Diabete
0	0.96842105	0.03157895
1	0.00000000	1.00000000

Il mosaic plot della distribuzione di FamilyHistory rispetto alla variabile risposta, evidenzia questa differenza tra gli "0" (non avere una storia familiare di diabete) e gli "1" (avere una storia familiare di diabete) di FamilyHistory rispetto al diabete.

Variabile MedicationUse:

Dal grafico si nota che una quota maggiore di individui senza diabete fa uso di farmaci specifici rispetto a quelli con diabete. Questo potrebbe indicare che l'uso di farmaci specifici non è un fattore determinante per l'insorgenza del diabete.

Distribuzione di MedicationUse rispetto a Outcome




	No Diabete	Si Diabete
0	0.8132099	0.1867901
1	0.7604200	0.2395800

Variabile Age:

	No Diabete	Si Diabete
18-35	0.8125313	0.1874687
35-53	0.8153846	0.1846154
53-71	0.7912596	0.2087404
71-89	0.74581977	0.2518023


Distribuzione Percentuale di Outcome nelle Classi di Età



Si può notare come per tutte le classi di età c'è un equilibrio tra gli individui che non hanno il diabete ma che diminuisce leggermente nella classe 71-89, mentre sembrerebbe che al crescere dell'età, aumenti la percentuale di individui con il diabete.

Variabile BMI:


	No Diabete	Si Diabete
<18.5	0.8171091	0.1828909
18.5-24.9	0.8278404	0.1721596
25-29.9	0.7978723	0.2021277
≥30	0.7444211	0.2555789

Distribuzione Percentuale di Outcome nelle Classi di BMI

Si può notare come all'aumentare del BMI la percentuale degli individui con il diabete aumenti gradualmente mentre la percentuale degli individui che non hanno il diabete diminuisca leggermente, suggerendo che un BMI alto potrebbe contribuire nell'insorgenza del diabete.

Variabile Glucose:


	No Diabete	Si Diabete
< 100	0.8178112	0.1821888
100-125	0.8231132	0.1768868
≥126	0.6504559	0.3495441

Distribuzione Percentuale di Outcome nelle Classi di Glucose

Dal grafico si nota che per i livelli di glucose sembra esserci una certa omogeneità sia per gli individui che hanno il diabete che per quelli che non hanno il diabete se hanno valori di Glucose tra <100 e 125, un dato interessante invece è che per valori ≥ 126 la percentuale di individui che hanno il diabete aumenta e la percentuale di individui che non hanno il diabete diminuisca suggerendo, che per valori alti di Glucose è probabile che si sviluppi il diabete.

Variabile BloodPressure:


	No Diabete	Si Diabete
<120	0.8184480	0.1815520
120-129	0.7645663	0.2354337
130-139	0.3333333	0.6666667



Dal grafico si nota subito che tra la pressione sanguigna <120 e 129 la percentuale degli individui con il diabete aumenta leggermente per poi aumentare in maniera significativa per la pressione 130-139 avendo una percentuale di individui con il diabete del 66% contro il 33% dei non diabetici, suggerendo che potrebbe esserci una relazione tra BloodPressure elevata e il diabete.

Variabile LDL:


	No Diabete	Si Diabete
<100	0.7956827	0.2043173
100-129	0.7895717	0.2104283
130-159	0.7796014	0.2203986
160-189	0.8043478	0.1956522
≥ 190	0.7142857	0.2857143



Si può notare come per le classi di LDL le percentuali di individui con diabete e senza siano simili, registrando però un aumento della percentuale di diabetici per valori ≥ 190 , mentre è interessante che per i valori 160-189 ci sia una diminuzione della percentuale di diabetici.

Variabile HDL:


	No Diabete	Si Diabete
<40	0.7870778	0.212922
40-59	0.7910253	0.2089747
≥ 60	0.7996042	0.2003958



Si può notare come per le classi di HDL le percentuali di diabetici e non diabetici si mantengono sugli stessi livelli, suggerendo che HDL potrebbe non essere rilevante per l'insorgenza del diabete.

Variabile Triglycerides:


	No Diabete	Si Diabete
<150	0.7933061	0.2066939
150-199	0.7872501	0.2127499
200-499	0.7987988	0.2012012



Si può notare come per le classi di Triglycerides le percentuali di diabetici e non diabetici si mantengono sugli stessi livelli, suggerendo che Triglycerides potrebbe non essere rilevante per l'insorgenza del diabete.

Variabile HbA1c:


	No Diabete	Si Diabete	Totale
< 5.7	0.80035833	0.199964167	7814
5.7-6.4	0.2531646	0.97468354	79
>6.4	0.0000000	1.0000000	4



Dal grafico si nota subito come la percentuale degli individui che hanno un livello di HbA1c "≥5.7" abbiano il diabete, essendoci percentuali non significative, quasi nulle di individui che non hanno il diabete in corrispondenza per quei valori di HbA1c. Possiamo concludere dicendo che potrebbe esserci una relazione importante tra HbA1c e l'insorgenza del diabete.


Variabile DietType:



	No Diabete	Si Diabete
Squilibrate	0.7917490	0.2082510
Bilanciata	0.8001788	0.1998212
Vegana/Vegetariana	0.8030942	0.1969058
Sconosciuta	0.7321429	0.2678571



Dal grafico si evince che le percentuali dei diabetici in corrispondenza delle diverse tipologie di diete siano simili ad eccezione della dieta “Sconosciuta”, ma in quel caso bisognerebbe fare un’analisi più approfondita, perciò si potrebbe ipotizzare che la tipologia di dieta potrebbe non essere rilevante per l’insorgenza del diabete.

Variabili WaistCircumference, HipCircumference, WHR :





Dai boxplot relativi a WaistCircumference, HipCircumference e WHR si nota che il “Si diabete” sia leggermente più variabile del “No Diabete”, in tutti vi è la presenza di diversi outliers specialmente in corrispondenza dei «No diabete». Si può concludere che queste 3 variabili potrebbero non avere una forte correlazione con l’insorgenza del diabete ma potrebbero fornire informazioni importanti al riguardo.

Modelli

Random Forest

Il Random Forest è un algoritmo di apprendimento basato su un insieme di alberi decisionali. Ogni albero è costruito utilizzando un campione casuale del dataset e una selezione casuale di variabili, riducendo così la varianza e migliorando la robustezza del modello. Ad ogni passo si seleziona infatti solo un sottoinsieme casuale di predittori, indicato in R con `mtry`. Infine, si calcola la media delle previsioni.

Il 75% dei dati è stato utilizzato per il training, mentre il restante 25% è servito per valutazione del modello.

Sono stati sviluppati e valutati otto modelli distinti, ciascuno con configurazioni diverse degli iperparametri. Per ogni numero di predittori considerati (`mtry = 3, 4, 7, 10`) sono stati realizzati due modelli, di cui uno con 500 e uno con 1000 alberi. È stato inoltre utilizzato un parametro per dare un peso maggiore a “1” della variabile risposta per ridurre l’influenza dello sbilanciamento delle sue classi (alla classe 0 si è dato peso uguale a 1 mentre per la classe 1 si è dato peso uguale a $6256/1641$, ovvero il rapporto tra le osservazioni della classe 0 diviso le osservazioni della classe 1).

Per valutare il miglior modello, sono state costruite le confusion matrix sulle previsioni per ciascun modello e da questi sono state estratte le metriche Accuracy, Sensitivity, Specificity, Positive Predictive Value e F1-Score. La scelta del modello migliore è stata basata su un buon compromesso tra Sensitivity e F1-Score, poiché l’obiettivo è prevedere l’insorgenza del diabete. La Sensitivity è stata privilegiata per ridurre il numero di falsi negativi, mentre l’F1-Score aiuta a mantenere un equilibrio tra Positive Predictive Value e Sensitivity, evitando un eccesso di falsi positivi. Pertanto, selezionare un modello che ottimizzi entrambe queste metriche rappresenta la scelta più adeguata.

La confusion matrix del modello scelto è la seguente:

Valori reali Previsione	0	1
0	1576	35
1	1	363

La matrice evidenzia che vi sono 1576 previsioni per “0” (no diabete) di Outcome, che sono realmente “0”, cioè veri negativi (TN); Il modello ha erroneamente previsto che 35 individui hanno il diabete “1” quando in realtà non lo hanno (FP); c’è un solo falso negativo, ovvero si pensa non abbia il diabete quando in realtà lo ha (FN); 363 sono invece i veri positivi, cioè coloro hanno realmente il diabete(TP).

Queste previsioni molto alte per 0 sono dovute allo sbilanciamento del dataset, nonostante questo l’accuracy sembra ottima (pari all’98,18%), così come la specificity (91,21%, il modello prevede bene i veri negativi), si nota una sensitivity molto alta di circa il 99,94%, che misura la capacità del modello di identificare correttamente i veri positivi (ovvero chi ha il diabete), inoltre il Positive Predictive Value è pari a 97,82% e l’F1-Score è uguale a 98,87%, quindi questo risulta essere un ottimo modello.


Accuracy	0.9817722
Sensitivity	0.9993659
Specificity	0.9120603
Positive Predictive Value	0.9782744
F1-Score	0.9887077

Sul modello scelto, si controlla l’importanza delle variabili:

Per valutare l’importanza delle variabili nel modello Random Forest MRF6, sono stati analizzati due indicatori:

1. **Mean Decrease Accuracy**, che misura l’impatto della rimozione di una variabile sull’accuratezza complessiva del modello.
2. **Mean Decrease Gini**, che indica il contributo della variabile nella separazione tra le classi all’interno degli alberi decisionali.

Visto che l’obiettivo è fare previsioni prendiamo in considerazione il Mean Decrease Accuracy che risulta l’indicatore migliore per valutare l’impatto complessivo delle variabili sulla previsione.



Dall'analisi del **Mean Decrease Accuracy** emerge che:

- **Family History** è la variabile più rilevante, la sua rimozione comporterebbe una forte riduzione dell'accuratezza del modello, confermando, come visto precedentemente nell'analisi esplorativa, il ruolo importante della predisposizione genetica nel rischio di diabete.
- Come ipotizzato nell'analisi esplorativa, la variabile **HbA1c** risulta tra le variabili più importanti, una sua eliminazione ridurrebbe la capacità del modello di effettuare previsioni accurate.
- **Glucose, WaistCircumference , HipCircumference e WHR** mostrano un impatto importante, ma leggermente inferiore rispetto alle variabili precedenti.
- Variabili come **Blood Pressure, LDL e BMI** hanno un valore molto basso, suggerendo che la loro rimozione avrebbe un impatto trascurabile sull'accuratezza del modello.

Quindi, in termini di accuratezza, le variabili più determinanti sembrano essere **Family History e HbA1c**.

Boosting

Il boosting è un metodo di apprendimento che costruisce una serie di alberi decisionali cercando di correggere gli errori commessi dagli alberi precedenti.

Come richiesto, il 75% dei dati è stato utilizzato per il training, mentre il restante 25% stato utilizzato per il test del modello.

Anche in questo caso sono stati realizzati otto modelli, regolando i principali iperparametri, quali il numero di alberi, la profondità massima degli alberi e il parametro di shrinkage (tasso di apprendimento). Si utilizza anche il parametro "cv.folds", ovvero cross-validation, per valutare le prestazioni del modello di Boosting in modo più robusto e per evitare l'overfitting.

Per valutare le performance predittive dei modelli, come è stato fatto precedentemente per il Random Forest, sono state costruite le confusion matrix sulle previsioni per ciascun modello e da questi sono state estratte le metriche Accuracy, Sensitivity, Specificity, Positive Predictive Value e F1-Score. La scelta del modello migliore è stata basata su un buon compromesso tra Sensitivity e F1-Score, poiché l'obiettivo è prevedere l'insorgenza del diabete. Oltre alle metriche di performance, si considera anche il numero ottimale di alberi. A parità di risultati, si preferisce il modello con il numero più basso di alberi, poiché garantisce buone prestazioni riducendo il rischio di overfitting e ottimizzando il consumo di risorse.

La confusion matrix del modello scelto è la seguente:


Previsione \ Valori reali	0	1
0	1566	37
1	0	372

La matrice evidenzia che vi sono 1576 previsioni per "0" (no diabete) di Outcome, che sono realmente "0", cioè veri negativi (TN); Il modello ha erroneamente previsto che 37 individui hanno il diabete ("1") quando in realtà non lo hanno (FP); non ci sono falsi negativi, ovvero si pensa non abbiano il diabete quando in realtà lo hanno (FN); 372 sono invece i veri positivi, cioè coloro hanno realmente il diabete (TP).

Anche in questo caso previsioni molto alte per 0 sono dovute allo sbilanciamento del dataset, nonostante questo l'accuracy sembra ottima (pari all'98,12%), così come la specificity (90,95%) , si nota una sensitivity perfetta dell' 1%, inoltre il Positive Predictive Value è pari a 97,69% e l'F1-Score è uguale a 98,83%, numero di alberi pari a 166, quindi questo risulta essere un ottimo modello.

Accuracy	0.9812658
Sensitivity	1.0000000
Specificity	0.9095355
Positive Predictive Value	0.9769183
F1-Score	0.9883244
N.trees	166

Una volta identificato, si guarda il numero di alberi ottimale riscontrato da quel modello.




Il grafico mostra come il modello stia imparando rapidamente e si adatta bene ai dati.

Il numero ottimale di iterazioni (alberi), indicato dalla linea tratteggiata blu, è pari a 166 questo è il punto in cui il modello ha raggiunto un buon equilibrio tra la riduzione dell'errore e la prevenzione dell'overfitting.

Dopo circa 100 iterazioni, la diminuzione dell'errore rallenta e le curve tendono a stabilizzarsi. Questo suggerisce che il modello ha raggiunto un punto in cui ulteriori iterazioni non portano a miglioramenti significativi nelle prestazioni.

Sono state poi individuate le variabili ritenute importanti dal modello di Boosting scelto



Dal grafico si nota come la variabile più rilevante sia **FamilyHistory**, come visto pure precedentemente sia nel Random Forest che nell’analisi esplorativa, confermando l’importanza di questa variabile nello studio. Ci sono altre due variabili importanti ovvero **Glucose** e **HbA1c**, che hanno la stessa rilevanza a differenza del Random Forest dove HbA1c sembra essere più importante; **WaistCircumference** e **HipCircumference** hanno un impatto importante ma non quanto le altre variabili. Le altre variabili invece hanno un valore molto basso e sembrerebbero non avere un impatto importante sul modello in termini di accuratezza. Quindi si può concludere che le variabili più rilevanti sembrerebbero essere: **FamilyHistory**, **Glucose** e **HbA1c**.

Conclusioni

Nel presente studio sono state analizzate le performance predittive di due diversi modelli: Random Forest (RF) e Boosting. Durante l'analisi esplorativa, sono emerse alcune variabili chiave che sembrano avere un impatto significativo sulla previsione della variabile di risposta (insorgenza diabete). Le variabili FamilyHistory, HbA1c e Glucose sono risultate cruciali in entrambi i modelli, oltre che nell’analisi esplorativa.

Nel confronto tra i due modelli predittivi, tenendo in considerazione che la variabile di risposta (Outcome) è sbilanciata, in situazioni come questa l'accuracy potrebbe non essere un indicatore delle performance del modello, in quanto potrebbe non riflettere adeguatamente la capacità di distinguere tra le classi minoritarie e maggioritarie. Per questo motivo, si è deciso di confrontare la sensitivity tra i due modelli, risultando più alta, quindi migliore, nel modello di boosting. Inoltre si è confrontato anche F1-Score di entrambi i modelli risultando maggiore nel Random Forest.

Si può concludere che entrambi i modelli risultano essere dei buoni modelli, ma si preferisce il boosting poiché ha una sensitivity perfetta che è cruciale per minimizzare i falsi negativi per lo studio svolto.

Modello	Sensitività	F1-Score
M5_boost	1.0000000	0.9883244
MRF6	0.9993659	0.9887077